

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ОДЕСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ імені І.І. МЕЧНИКОВА
Факультет математики, фізики та інформаційних технологій
Кафедра математичного забезпечення комп'ютерних систем

ЛАБОРАТОРНА РОБОТА №2

з дисципліни
«Інтелектуальний аналіз даних»

на тему:

Лінійна регресія в Excel

студента 4 курсу
спеціальності: Інформаційні системи і технології

Краковський Владислав Олександрович

(Прізвище, ім'я та по батькові)

Викладач: доц. Петрушина Т.І.

(Прізвище, ім'я та по батькові)

Одеса – 2026

1. Постановка задачі:

Виконати практичні завдання, надані в кінці розділу #2 «Excel And Data Mining» книги «Learn Data Mining Through Excel».

2. Хід роботи:

Завдання буде виконуватися в Excel та на Python

1. Побудова множинної лінійної регресії в Excel

У завданні використовувалися декілька факторів:

- кількість випускників шкіл;
- економічний стан США;
- вартість навчання;
- фінансова стипендія;
- фінансова допомога;
- кількість відвідувачів open house;
- рекламний бюджет;
- admission activities;
- SAT cutoff.

Цільовою змінною була кількість студентів першого курсу.

Для знаходження коефіцієнтів множинної регресії використовувалась функція

=ЛИНЕЙН(K\$19:K\$28;B\$19:J\$28;ИСТИНА;ИСТИНА)

Оскільки функція ЛИНЕЙН повертає масив значень, для отримання окремих коефіцієнтів використовувалась функція:

=ИНДЕКС(ЛИНЕЙН(K\$19:K\$28;B\$19:J\$28;ИСТИНА;ИСТИНА);1;N19)

У результаті були отримані коефіцієнти регресії для кожного фактора.

C32	=ИНДЕКС(ЛИНЕЙН(K\$19:K\$28;B\$19:J\$28;ИСТИНА;ИСТИНА);1;B32)		
	A	B	C
7			
8	Year	Num high school graduates	USA Economics
9	2004	25000	3
0	2005	25600	3
1	2006	24367	3
2	2007	25500	3
3	2008	28321	2
4	2009	28759	1
5	2010	25431	1
6	2011	24678	1
7	2012	24987	2
8	2013	25100	2
9	NEW YEAR	25500	3
0		x1	x2
1			..
2	SAT cutoff	1	0,03316125
3	admission activities	2	1,394947044
4	media advertisement investment	3	-0,003520058
5	number of open house visitors	4	0,028911714
6	financial aid available	5	-1,042935898
7	financial scholarship	6	-3,426954888
8	comparable tuition fee	7	-3,091309121
9	USA Economics	8	12,76836133
0	Num high school graduates	9	0,008022617
1	intercept	10	-67,0583926

Рисунок 1: Формула коефіцієнтів

Після цього було виконано прогнозування кількості студентів для нового року.

Формула прогнозу:

$$=J29*\$C\$32+I29*\$C\$33+H29*\$C\$34+G29*\$C\$35+F29*\$C\$36+E29*\$C\$37+D29*\$C\$38+C29*\$C\$39+B29*\$C\$40+\$C\$41$$

У результаті модель спрогнозувала: приблизно 220 студентів першого курсу.

=J29*\$C\$32+I29*\$C\$33+H29*\$C\$34+G29*\$C\$35+F29*\$C\$36+E29*\$C\$37+D29*\$C\$38+C29*\$C\$39+B29*\$C\$40+\$C\$41							
E	F	G	H	I	J	K	
a.							
T cutoff, admission activities, media advertisement investment, number of open house visitors, financial aid available, financial scholarship, comparable tuition fee,							
financial scholarship	financial aid available	number of open house visitors	media advertisement investment	admission activities	SAT cutoff	Number of First Year Enrollment	
3	1	1100	13400	20	1000	200	
1	2	1005	12900	15	980	202	
2	3	900	8000	8	950	188	
2	3	980	8000	11	1020	209	
3	1	1212	7500	18	1000	232	
3	3	1220	10000	19	1010	220	
1	1	987	8000	10	950	188	
1	2	899	7500	8	1000	179	
2	3	1488	11000	7	1000	190	
2	3	900	11000	10	1000	175	
2	2	1130	9000	20	1000	219,6596244	

Рисунок 2: Прогноз

2. Реалізація множинної лінійної регресії у Python

Для реалізації моделі використовувались бібліотеки NumPy та Pandas.

```
[3]: import numpy as np
import pandas as pd

# Исторические данные
data = {
    "Year": [2004, 2005, 2006, 2007, 2008, 2009, 2010, 2011, 2012, 2013],
    "Num high school graduates": [25000, 25600, 24367, 25500, 28321, 28759, 25431, 24678, 24987, 25100],
    "USA Economics": [3, 3, 3, 3, 2, 1, 1, 1, 2, 2],
    "Comparable tuition fee": [2, 2, 3, 2, 3, 1, 1, 1, 2, 3],
    "Financial scholarship": [3, 1, 2, 2, 3, 3, 1, 1, 2, 2],
    "Financial aid available": [1, 2, 3, 3, 1, 3, 1, 2, 3, 3],
    "Number of open house visitors": [1100, 1005, 900, 980, 1212, 1220, 987, 899, 1488, 900],
    "Media advertisement investment": [13400, 12900, 8000, 8000, 7500, 10000, 8000, 7500, 11000, 11000],
    "Admission activities": [20, 15, 8, 11, 18, 19, 10, 8, 7, 10],
    "SAT cutoff": [1000, 980, 950, 1020, 1000, 1010, 950, 1000, 1000, 1000],
    "Enrollment": [200, 202, 188, 209, 232, 220, 188, 179, 190, 175]
}

df = pd.DataFrame(data)
df
```

	Year	Num high school graduates	USA Economics	Comparable tuition fee	Financial scholarship	Financial aid available	Number of open house visitors	Media advertisement investment	Admission activities	SAT cutoff	Enrollme
0	2004	25000	3	2	3	1	1100	13400	20	1000	2
1	2005	25600	3	2	1	2	1005	12900	15	980	2
2	2006	24367	3	3	2	3	900	8000	8	950	1
3	2007	25500	3	2	2	3	980	8000	11	1020	2
4	2008	28321	2	3	3	1	1212	7500	18	1000	2
5	2009	28759	1	1	3	3	1220	10000	19	1010	2
6	2010	25431	1	1	1	1	987	8000	10	950	1
7	2011	24678	1	1	1	2	899	7500	8	1000	1
8	2012	24987	2	2	2	3	1488	11000	7	1000	1
9	2013	25100	2	3	2	3	900	11000	10	1000	1

Побудова моделі

```
[4]: # Признаки X
X = df[
    [
        "Num high school graduates",
        "USA Economics",
        "Comparable tuition fee",
        "Financial scholarship",
        "Financial aid available",
        "Number of open house visitors",
        "Media advertisement investment",
        "Admission activities",
        "SAT cutoff"
    ]
].values

# Целевая переменная y
y = df["Enrollment"].values

# Добавляем столбец единиц для intercept b
X_with_intercept = np.column_stack([X, np.ones(len(X))])

# Находим коэффициенты методом наименьших квадратов
coefficients = np.linalg.lstsq(X_with_intercept, y, rcond=None)[0]

coefficients

[4]: array([ 8.02261705e-03,  1.27683613e+01, -3.09130912e+00, -3.42695489e+00,
        -1.04293590e+00,  2.89117138e-02, -3.52005786e-03,  1.39494704e+00,
         3.31612503e-02, -6.70583926e+01])
```

```
[5]: coef_names = [
    "Num high school graduates",
    "USA Economics",
    "Comparable tuition fee",
    "Financial scholarship",
    "Financial aid available",
    "Number of open house visitors",
    "Media advertisement investment",
    "Admission activities",
    "SAT cutoff",
    "Intercept"
]

coef_table = pd.DataFrame({
    "Coefficient": coef_names,
    "Value": coefficients
})

coef_table
```

```
[5]:
```

	Coefficient	Value
0	Num high school graduates	0.008023
1	USA Economics	12.768361
2	Comparable tuition fee	-3.091309
3	Financial scholarship	-3.426955
4	Financial aid available	-1.042936
5	Number of open house visitors	0.028912
6	Media advertisement investment	-0.003520
7	Admission activities	1.394947
8	SAT cutoff	0.033161
9	Intercept	-67.058393

Прогнозування нового року

```
[6]: new_year = np.array([
    25500, # Num high school graduates
    3,     # USA Economics
    3,     # Comparable tuition fee
    2,     # Financial scholarship
    2,     # Financial aid available
    1130,  # Number of open house visitors
    9000,  # Media advertisement investment
    20,    # Admission activities
    1000,  # SAT cutoff
    1      # Intercept
])

prediction = new_year @ coefficients

prediction

[6]: np.float64(219.6596243825801)

[7]: print(f"Predicted number of first year enrollment: {prediction:.2f}")
Predicted number of first year enrollment: 219.66
```

Отриманий результат: 219.6596244

Результат прогнозування у Python збігся з результатом, який був отриманий у Excel.

Висновки щодо роботи

У результаті виконання лабораторної роботи було вивчено принципи роботи простої та множинної лінійної регресії.

Було реалізовано побудову моделей у Microsoft Excel та Python.

У ході роботи було отримано навички:

- побудови регресійних моделей;
- використання функцій Excel для аналізу даних;
- використання Python для прогнозування;
- роботи з методом найменших квадратів;
- аналізу та прогнозування даних.

Отримані результати показали, що Excel та Python дозволяють ефективно виконувати задачі інтелектуального аналізу даних та прогнозування на основі історичних даних.